

**1. (20 puntos) Investiga los siguientes conceptos asociados a problemas de clasificación binaria.**

- Confusion matrix

La matriz de confusión es una tabla que se utiliza para describir el rendimiento de un modelo de clasificación principalmente binario. Esta se divide en apartado de predicciones y apartado de realidad, arrojando los resultados pertinentes respecto al algoritmo que hayamos utilizado. Ahora se definen los términos básicos.

Verdaderos positivos (TP). Estos casos son los que se predijo que toman el valor de sí, y sí están en los correcto.

Verdaderos negativos (TN). Son los que se predijo que no y el valor verdadero es no.

Falsos positivos (FP). Son los que se predijo que sí, pero en realidad el valor verdadero es no.

Falsos negativos (FN). Son los que el modelo predijo que no, pero el valor verdadero es sí.

- Accuracy

La exactitud es una métrica para evaluar rendimiento de la clasificación, esta mide en un porcentaje los casos en el que el modelo ha acertado.

El problema con esta métrica es que nos puede engañar fácilmente haciendo que un mal modelo parezca mucho mejor de lo que es.

$$accuracy = \frac{TP + TN}{N}$$

- Recall.

La exhaustividad es una métrica que mide la proporción de la población en la que la condición de la prueba se predijo como positivo. También conocido como true positive rate (el radio del verdadero positivo).

$$recall = \frac{TP}{TP + FN}$$

- Precision

La precisión es la métrica de la proporción de la población que mide la fracción de positivos reales entre los resultados de prueba que se predicen como positivos. También conocido como positive predictive value (valor predictivo positivo).

$$precision = \frac{TP}{TP + FP}$$

- F1. F-Score, Valor-F

F-Score es la métrica que se utiliza para combinar las medidas de precision y recall para así poder observar y comparar más fácil y detalladamente el rendimiento combinado de las medidas de la clasificación entre varias soluciones.

$$F1 = 2 \cdot \frac{precision \cdot recall}{precision + recall}$$

**5. (15 puntos opcionales) Ve el video [www.youtube.com/watch?v=wmyVODy\\_WD8](https://www.youtube.com/watch?v=wmyVODy_WD8) y reflexiona sobre el mismo. Apunta aquí tus observaciones sobre los temas tratados.**

#### Algorithmic Bias y Fairness

El significado general de Bias podríamos tomarlo como prejuicio, establecer una serie de normalidad en base a nuestros propios prejuicios o un BIAS basado en algoritmos.

El problema general del Bias algorítmico es que este ha sido llevado a cabo en base a Estados Unidos, Canadá y Europa del Oeste. Por lo que todo lo que no esté dentro de eso suele ser mal interpretado por programas de análisis de imagen. Por ejemplo, fallas en programas de detección de rostros.

En este video comparan y analizan 2 tipos de Bias, uno de interpretación y uno de datos, el bias basado en interpretación puede generar bias en base a correlación entre temas, este método puede empezar a generar errores al momento de generalizar el sujeto que se quiere analizar. El bias de datos se construye a partir de selección y muestreo. Este proceso puede empezar a mostrar problemas al momento de en el que la muestra empieza a estar desbalanceada y nuestro programa genera un bias en base a lo más frecuente. Esto es malo porque un programa empieza a fallar al momento de analizar cosas poco comunes. La solución es dar más peso a lo poco frecuente y menos peso a lo más frecuente. Si el problema de estos sistemas es que tienen un bias bien definido hay que encontrar maneras de reducir ese bias, mejorando desde la base por ejemplo definir más equitativamente todos sus datos en que basarse. Otra manera de eliminar el bias es diseñar el modelo para que no haga caso a esos bias. También habría que resamplear nuestros modelos para que tengan más variedad en sus datos y adaptarlos para que hagan muestre más justo y balanceado.

### **Referencias para el punto 1.**

[Simple guide to confusion matrix terminology \(dataschool.io\)](https://dataschool.io/confusion-matrix/)

[How to Calculate Precision, Recall, and F-Measure for Imbalanced Classification \(machinelearningmastery.com\)](https://machinelearningmastery.com/how-to-calculate-precision-recall-f-measure-for-imbalanced-classification/)

[Binary classification - Wikipedia](https://en.wikipedia.org/wiki/Binary_classification)

[Clasificación binaria - Amazon Machine Learning](https://aws.amazon.com/machine-learning/binary-classification/)

[Precision, Recall, F1, Accuracy en clasificación - lArtificial.net](https://lartificial.net/precision-recall-f1-accuracy-en-clasificacion/)